

PROYECTO FINAL · DATA SCIENTIST II

Predicción de Precios de Arriendo en la Región Metropolitana

Modelamiento predictivo y evaluación de modelos de Machine Learning

Contexto y problema

Del análisis exploratorio a una herramienta de estimación de precios.

El mercado de arriendos presenta alta variabilidad según ubicación, superficie, gastos comunes y características del inmueble. La entrega final modela esta variabilidad como un problema predictivo.

Regresión

Tipo de problema ML

precio

Variable objetivo

RM

Alcance geográfico

ML

Resultado esperado



Variables clave: superficie · comuna · dormitorios · baños · gastos comunes · ubicación

Preparación de datos

Limpieza orientada a construir una base consistente para modelamiento.

1

Selección de variables

Se eliminaron identificadores, enlaces, títulos, códigos y fechas.

2

Corrección de superficies

Valores como 5438 o 7094 fueron tratados como errores de escala.

3

Tratamiento de nulos

Estacionamientos y bodegas ausentes se imputaron como 0.

4

Filtrado de registros

Se mantuvieron rangos razonables de precio, superficie, dormitorios y baños.

Objetivo: reducir ruido sin perder registros útiles para el aprendizaje del modelo.

Superficies

Nulos

Outliers

Data leakage

Nuevas variables para capturar comportamiento inmobiliario

Se crearon variables derivadas para representar presencia de amenidades, costos relativos y densidad de uso del espacio.

tiene_estacionamiento

tiene_bodega

terraza_ratio

gasto_comun_por_m2

densidad_dormitorios

densidad_banos


zona_comuna

La agrupación de comunas permite incorporar una lectura territorial más robusta.



Estrategia de modelamiento

Comparación de modelos base, optimizados y ensemble.



Preprocesamiento común

- ✓ Imputación de valores faltantes
- ✓ Estandarización de variables numéricas
- ✓ One Hot Encoding para variables categóricas
- ✓ Validación cruzada y RandomizedSearchCV

Resultados comparativos

El criterio principal fue MAE por su interpretación directa en pesos chilenos.



Tabla de resultados

Modelo	MAE	RMSE	R ²
Random Forest Opt.	\$45.712	\$90.493	0.9023
Gradient Boosting Opt.	\$47.722	\$88.681	0.9062
Voting Regressor	\$47.902	\$83.909	0.9160
Gradient Boosting	\$48.849	\$83.083	0.9176
Ridge Regression	\$52.016	\$88.446	0.9067

Modelo seleccionado: Random Forest Optimizado

Elegido por menor error promedio absoluto.

\$45.712



MAE · error promedio

\$90.493



RMSE · penaliza errores grandes

0.9023



R^2 · capacidad explicativa

Justificación

Se priorizó MAE porque permite explicar el desempeño en pesos chilenos. Aunque otros modelos presentan mejor R^2 , Random Forest Optimizado tuvo el menor error promedio.

Interpretación de uso

- ✓ Apoya estimación inicial de precios
- ✓ Permite comparar propiedades similares
- ✓ Detecta posibles valores sobre/subvalorados

CONCLUSIONES

De EDA a modelo predictivo aplicable al mercado inmobiliario

El proyecto construye un flujo completo de Machine Learning para estimar precios de arriendo con precisión razonable y lectura de negocio.

- ✓ Random Forest Optimizado fue el modelo final por menor MAE.
- ✓ El modelo es útil como apoyo, no como tasación definitiva.
- ✓ Mejoras futuras: metro, antigüedad, seguridad, conectividad y equipamiento urbano.

Gracias

Vicente Tejos · Data Scientist II